

一、基础操作指令

指令	功能	示例
<code>ollama run <模型名></code>	运行指定模型（自动下载若不存在）	<code>ollama run llama3</code>
<code>ollama list</code>	查看本地已下载模型列表	<code>ollama list</code>
<code>ollama pull <模型名></code>	手动下载模型	<code>ollama pull mistral</code>
<code>ollama rm <模型名></code>	删除本地模型	<code>ollama rm llama2</code>
<code>ollama help</code>	查看帮助文档	<code>ollama help</code>

二、模型交互指令

1. 直接对话

```
1 | ollama run llama3 "用中文写一首关于秋天的诗"
```

2. 进入交互模式

```
1 | ollama run llama3
2 | # 进入后输入内容，按 Ctrl+D 或输入 `/bye` 退出
```

3. 从文件输入

```
1 | ollama run llama3 --file input.txt
```

4. 流式输出控制

参数	功能	示例
<code>--verbose</code>	显示详细日志	<code>ollama run llama3 --verbose</code>
<code>--nowordwrap</code>	禁用自动换行	<code>ollama run llama3 --nowordwrap</code>

三、模型管理

1. 自定义模型配置 (Modelfile)

创建 `Modelfile` 文件：

```
1 | FROM llama3 # 基础模型
2 | PARAMETER temperature 0.7 # 控制随机性 (0-1)
3 | PARAMETER num_ctx 4096 # 上下文长度
4 | SYSTEM "" 你是一个严谨的学术助手，回答需引用论文来源。 "" # 系统提示词
```

构建自定义模型：

```
1 ollama create my-llama3 -f Modelfile
2 ollama run my-llama3
```

2. 查看模型信息

```
1 ollama show <模型名> --modelfile # 查看模型配置
2 ollama show <模型名> --parameters # 查看运行参数
```

四、高级功能

1. API 调用

启动 API 服务

```
1 ollama serve
```

通过 HTTP 调用

```
1 curl http://localhost:11434/api/generate -d '{
2     "model": "llama3",
3     "prompt": "你好",
4     "stream": false
5 }'
```

2. GPU 加速配置

```
1 # 指定显存分配比例 (50%)
2 ollama run llama3 --num-gpu 50
```